



Predictive Policingモデル再現実験：公開データ・実運用アルゴリズム・実行手順書

🕒 作成日時	2026年9月14日 17:16
☰ タグ	

調査日：2026年9月14日

改訂：2026年9月14日（適応ETAS版）

用途：Predictive Policingの場所型モデルを公開犯罪データで再現し、**新しい事件が到着するたびに予測状態が変わり、一定間隔でモデル自体も適応する過程**を技術的に確認するための実験準備メモ

関連：[Predictive Policingに関する調査](#)、[詳細事例② PredPol/Geolitica — 技術・運用・評価](#)、[詳細事例④ Philadelphia 3PE — 予測と巡回方法の比較実験](#)



改訂後の結論：第一実験はLos Angeles公開犯罪データと、LAPD・Kent Policeで実運用試験されたETAS型モデルを用いる。ただし中心課題を「固定パラメータETASの一括再計算」から、**事件ごとの状態更新+週次のローリング再推定を行う適応ETAS**へ変更する。比較対象として固定hotspot、固定パラメータETAS、毎日再推定ETAS、完全オンライン学習を同じ時系列評価で並べる。商用製品そのものではないため、成果物では「公開論文仕様を基礎とするAdaptive PredPol-like ETAS」と表記する。

1. この実験の範囲

2. 利用する公開データ

2.1 第一候補：Los Angeles

2.2 時刻列を二つ持つ

3. 基礎モデル：ETASを何として予測するか

4. 適応ETASの設計

4.1 状態更新：事件ごとに必ず行う

4.2 パラメータ適応：週次を標準とする

4.3 忘却係数を持つ適応尤度

4.4 完全オンライン学習は比較実験とする

5. 比較する実験条件

6. 実行手順書：LAPD × Adaptive PredPol-like ETAS

Step 0：研究質問を固定する

Step 1：実行環境を作る

Step 2：データを取得する

Step 3：cleaningする

Step 4：150 m格子を作る

Step 5：時間分割を固定する

Step 6：初期パラメータを推定する

Step 7：test-then-updateで逐次実行する

Step 8：baselineも同じ情報条件で更新する

Step 9：保存する評価指標

Step 10：最低限作る図

7. 推奨する適応設定

8. 観測・巡回feedback実験

設定

観察項目

9. 外部再現と複雑モデルへの接続

Chicago

複雑化の比較候補

10. 実験記録template

11. 実装の合格条件

数値実装

時系列評価

出力解釈

12. 着手順

13. 参考資料

[公式データ](#)

[ETAS・SEPP・オンライン学習](#)

[比較モデル・実運用評価](#)

[関連Notion資料](#)

1. この実験の範囲

本メモは人物を順位づけるモデルではなく、**次の一定時間に犯罪が生じやすい小区画を順位づける場所型モデル**を対象とする。

- 入力の日時・位置・犯罪種を含む公的オープンデータに限定する。
- 出力は個人の危険度ではなく、格子ごとの条件付き発生率、期待件数、リスク順位である。
- Chicago SSLのような人物型予測は対象外とする。
- 公開データから商用PredPolの全前処理・パラメータ・配備ロジックを復元するのではなく、査読論文に公開されたETAS構造を再現・拡張する。
- 本実験が評価するのはtechnical efficacyと出力挙動であり、巡回による犯罪減少、制度的正当性、公平性の因果効果ではない。

添付システマティックレビューは、統制環境でのtechnical efficacy、現場のhuman-technology interaction、institutional contextを相互に関係する別条件として整理している。したがって、予測精度が高いことと社会的に望ましい運用であることを同一視しない。関連レビュー：[Conditions of benefits and risks when algorithmic technology is implemented for public sector policing and fraud detection: a systematic literature review](#)。

2. 利用する公開データ

候補	時間・位置情報	適応ETASとの対応	位置づけ
Los Angeles Crime Data 2010-2019	発生日・時刻、犯罪コード、LAPD Area、緯度経度	実運用試験と同じ都市・近い期間。事件単位の逐次再生が可能	第一実験
Chicago Crimes 2001-現在	日時、犯罪種、District、Beat、緯度経度。直近7日を除く	都市を変えた外部再現。SEPP公開実装との比較が可能	外部再現

候補	時間・位置情報	適応ETASとの対応	位置づけ
Philadelphia Crime Incidents	2006–現在。年別 CSV/SHP、API、日次更新	適応ETASとHunchLab型特徴量モデルの比較が可能	第2段階
<u>data.police.uk</u>	月単位・匿名化地点	時刻粒度が不足し、事件ごとのオンライン実験に不向き	補助候補

2.1 第一候補：Los Angeles

- 公式データ：[Crime Data from 2010 to 2019](#)
- API識別子：63jg-8b9z
- 重要列：DR_NO、Date Rptd、DATE OCC、TIME OCC、AREA、AREA NAME、Crm Cd、Crm Cd Desc、LAT、LON
- 境界データ：[LAPD MapServer](#)
- 推奨対象：最初は1 DivisionのBURGLARY。安定後にVEHICLE - STOLENと3 Divisionへ拡張する。
- 推奨期間：初期履歴を確保するため2011年5月16日以前から取得し、2012年5月16日–2013年1月10日を主要backtest期間とする。

Mohler et al. (2015) のLAPD試験と同時期を切り出せるが、公開履歴版は当時のlive records management systemのsnapshotではない。結果は「論文の厳密追試」ではなく、**同じ都市・近い期間・公開数値仕様による再現実験**として解釈する。

2.2 時刻列を二つ持つ

適応モデルでは、データがいつモデルへ到着したかが結果を左右する。必ず次を分離する。

- **event_time**：事件が発生したと記録された日時。科学的な事後再生用。
- **available_time**：モデルがその事件を知り得た日時。実運用再生用。

第一段階ではevent_time順で処理する。第二段階ではDate Rptd等からavailable_timeを構成し、報告遅延を含む擬似real-time評価を行う。同じ事件を発生時刻直後にモデルへ入力してしまう未来情報漏洩を避ける。

3. 基礎モデル：ETASを何として予測するか

中心文献：[Mohler et al. \(2015\), Randomized Controlled Field Trials of Predictive Policing](#)

LAPD/Kent試験の基本条件は次の通り。

- 警察管区を150 m × 150 m格子へ分割。
- 直近365日の犯罪を使用。
- 各管区・各12時間shiftにつき上位20格子を提示。
- 長期的な場所固有riskと、直近事件後に減衰する短期riskを合成。
- 毎日5:00に予測を更新し、6:00–18:00と18:00–6:00へ提示。

離散空間ETASの基本形を次とする。

$$\lambda_n(t) = \mu_n + \theta \omega z_n(t)$$

$$z_n(t) = \sum_{t_i < t} w_{n,n_i} \exp\{-\omega(t - t_i)\}$$

- n ：予測対象格子
- n_i ：事件 i が発生した格子
- μ_n ：格子 n の長期背景率
- θ ：一件が将来riskを励起する大きさ
- ω ：励起効果の時間減衰率
- $w_{\{n,n_i\}}$ ：事件格子から予測格子への空間重み

論文の縮約版では、同一格子だけを励起する $w_{\{n,n_i\}}=1(n=n_i)$ から開始する。拡張実験では、隣接格子にも影響が及ぶよう、距離で正規化したGaussian kernel等を使う。

予測時刻 T から h 時間先までの、現在までに観測された事件に基づく格子risk scoreは、

$$R_n(T, h) = \mu_n h + \theta z_n(T) \{1 - \exp(-\omega h)\}$$

と計算できる。これは予測区間内に新しい事件がまだ観測されない条件で現在の強度を積分したrisk scoreである。予測区間内に起きる将来事件の二次・三次誘発まで含む完全な分岐予測が必要な場合は、積分方程式またはbranching simulationを別途用いる。



名称の注意：以下は商用PredPolの完全複製ではない。公開論文のETASを基礎に、研究用の逐次更新とパラメータ適応を加えたモデルである。

4. 適応ETASの設計

「モデル更新」を二種類に分ける。

4.1 状態更新：事件ごとに必ず行う

パラメータ μ 、 θ 、 ω を固定している間、状態 z は過去事件を全件再計算せず更新できる。

前回更新時刻 t から新しい事件時刻 $t + \Delta$ まで、

$$z_n((t + \Delta)^-) = \exp(-\omega \Delta) z_n(t^+)$$

事件が格子 m で発生した直後、

$$z_n((t + \Delta)^+) = z_n((t + \Delta)^-) + w_{n,m}$$

とする。縮約版では事件が起きた格子だけに1を加える。この更新は新しい事件を取り込むたびに実行する。

4.2 パラメータ適応：週次を標準とする

推奨する主実験では、状態は事件ごと、パラメータは7日ごとに更新する。

1. 直近365日の事件を抽出する。
2. 前週の推定値を初期値として、EMまたは制約付き最尤法を実行する。
3. μ_n 、 θ 、 ω を更新する。
4. 新しい ω では古い z の意味が変わるため、直近履歴から z を再構築する。
5. 次の7日間は新しいパラメータを固定し、事件ごとの状態更新だけを行う。

この方式は、毎事件再学習より安定し、毎日365日分をゼロから学習するより計算量を抑えられる。

4.3 忘却係数を持つ適応尤度

concept driftへの追従を強める比較実験では、古い期間の寄与を減らす。

$$\mathcal{L}_k(\eta) = \sum_{j \leq k} \rho^{k-j} \left[\sum_{t_i \in I_j} \log \lambda_{n_i}(t_i; \eta) - \sum_n \int_{I_j} \lambda_n(t; \eta) dt \right]$$

- $\eta=(\mu, \theta, \omega)$
- I_j : 第j更新区間
- ρ : 忘却係数。 $\rho=1$ なら忘却なし。小さいほど最近の事件を重視する。

最初は ρ を 0.98、0.995、1.0 などからrolling validationで選ぶ。 θ は正規化kernelの分岐比として解釈できるため、暴走を避ける主実験では $0 \leq \theta < 1$ に制約する。 μ_n と ω には正の下限を置く。

4.4 完全オンライン学習は比較実験とする

日または事件ごとに、

$$\eta_k = \Pi_C (\eta_{k-1} + \gamma_k \nabla_{\eta} \ell_k(\eta_{k-1}))$$

として、瞬時尤度または日次尤度の勾配でパラメータを更新できる。 Π_C は正値性・安定性制約への射影である。

ただし、 ω を毎回変えると単一の z だけでは過去の減衰状態を正確に保持できない。そのため次のいずれかが必要になる。

- 有限のevent bufferから z を再計算する。
- 複数の固定 ω basisについて状態を並列保持する。
- kernelをオンライン推定する専用手法を用いる。

ノンパラメトリックなオンラインHawkes学習の代表例はYang et al. (2017), Online Learning for Multivariate Hawkes Processesである。これは研究上重要だが、最初の再現実験では主モデルにせず、週次ローリング再推定後の発展実験とする。

5. 比較する実験条件

条件	状態更新	パラメータ更新	目的
M0 固定hotspot	なし	365日count/KDE	単純baseline
M1 Batch ETAS	予測時に履歴から一括計算	固定または期間冒頭のみ	公開仕様の基本再現
M2 State-online ETAS	事件ごと	固定	逐次状態更新の効果・計算量を確認

条件	状態更新	パラメータ更新	目的
M3 Adaptive ETAS	事件ごと	7日ごと、直近365日、warm start	主実験
M4 Fast-adaptive ETAS	事件ごと	日次+忘却係数	適応速度と不安定性の比較
M5 Online Hawkes	事件または日ごと	online SGD／NPOLE-MHP	完全オンライン化の発展実験

M1とM2はパラメータと利用履歴が同じなら原理上ほぼ同じ予測を返す。両者の比較は精度差ではなく、**逐次実装が一括再計算と数値的に一致するか、処理時間・memoryがどれだけ減るか**を検証するunit testとして使う。

6. 実行手順書：LAPD × Adaptive PredPol-like ETAS

Step 0：研究質問を固定する

主質問：

公開犯罪記録を到着順に処理する適応ETASは、固定パラメータETASおよび365日固定hotspotより、同一面積予算で翌24時間／12時間の犯罪位置を安定して順位づけできるか。

副質問：

- 状態だけの逐次更新とパラメータ適応のどちらが予測変化を生むか。
- 適応頻度を週次から日次へ上げると精度は上がるか、それとも予測地図が不安定になるか。
- 報告遅延を再現すると、事後的なevent_time評価から性能がどの程度低下するか。
- 重点予測地域からの観測増加を学習へ戻すと、予測集中が自己強化されるか。

Step 1：実行環境を作る

```

```bash
python -m venv .venv
source .venv/bin/activate
python -m pip install --upgrade pip
python -m pip install pandas numpy scipy geopandas shapely pyproj scikit-learn matplotlib seaborn jupyter pyarrow requests
```

```

Python version、package lock、raw data取得日時、download URL、SHA-256 hashを保存する。

Step 2：データを取得する

Socrata APIから必要列・期間・LAPD Areaを限定して取得する。最初は1 Division、BURGLARY、2011年-2013年程度に絞る。

- 取得時点では犯罪種をdescriptionだけで決めず、Crm Cdとの対応を確認する。
- pagination途中の欠落・重複を件数で検査する。
- raw fileは変更せず、cleaned fileを別保存する。
- 研究期間より少なくとも365日前から取得する。

Step 3：cleaningする

1. DATE OCCとTIME OCCからevent_timeを作る。
2. Date Rptd等からavailable_time候補を作る。
3. DR_NO重複を確認する。
4. LAT/LONのnull、0、都市境界外を除外する。
5. WGS84からmeter単位の投影座標へ統一する。
6. Division polygonでclipする。
7. 除外前後件数、欠損率、重複率、報告遅延分布を保存する。
8. 複数犯罪種を混ぜず、犯罪種ごとに別モデルを作る。

Step 4：150 m格子を作る

- Division polygonのbounding box上に150 m × 150 m fishnetを作る。
- polygonと交差する格子だけを残す。
- 各事件を一つのcell_idへ割り当てる。
- 境界格子の実面積を保存する。
- 感度分析では300 m、500 mも使用する。

Step 5：時間分割を固定する

random splitは使用しない。

- 初期学習：各backtest開始時点より前の365日。

- validation：backtestより前の連続期間。
- test候補：2012年5月16日–2013年1月10日。
- 初回は24時間窓。安定後に6:00–18:00／18:00–6:00へ細分化する。
- 更新頻度、忘却係数、grid幅はvalidationで固定し、test結果を見て変更しない。

Step 6：初期パラメータを推定する

1. μ_n を365日cell rateまたは空間平滑化rateで初期化する。
2. θ と ω を制約付き最尤法で推定する。
3. 次にEMによるbackground／trigger分解を実装する。
4. sparse cellの μ_n には小さなpriorまたは空間平滑化を入れ、ゼロ固定を避ける。
5. 初期推定後、履歴事件から $z_n(T_0)$ を構築する。
6. log likelihood、branching ratio、収束履歴、推定値を保存する。

理論的前身：[Mohler et al. \(2011\)](#), [Self-Exciting Point Process Modeling of Crime](#)

Step 7：test-then-updateで逐次実行する

各予測cutoffについて順番を固定する。

1. cutoff時点の状態とパラメータだけで次の予測窓を予測する。
2. risk map、上位20格子、全格子の期待件数を保存する。
3. 予測窓が終了した後、実際の事件でmetricsを計算する。
4. 事件をavailable_time順に一件ずつ状態へ取り込む。
5. 更新日なら、cutoff以前だけを使ってパラメータを再推定する。
6. ω が変わった場合はevent bufferから状態 z を再構築する。
7. 次のcutoffへ進む。

```
```python
eta = fit_initial(history_365d)
state = rebuild_state(history_365d, eta)
event_buffer = history_365d.copy()
for cutoff in forecast_cutoffs:
 # 1. Test: cutoff時点で利用可能な情報だけを使う
```

```

risk = integrated_risk(state, eta, horizon_hours)
save_forecast(cutoff, risk)
2. 予測窓終了後に評価
observed = events_available_in_window(cutoff, horizon_hours)
save_metrics(score(risk, observed))
3. Train/update: 新着事件を時間順に取り込む
for event in observed.sort_values("available_time"):
 state.decay_to(event.available_time, eta.omega)
 state.add_event(event.cell_id, spatial_weights)
 event_buffer.append(event)
4. 週次の適応
if is_refit_day(cutoff):
 window = event_buffer.last_days(365)
 eta = fit_weighted_likelihood(
 window,
 init=eta,
 forgetting=rho,
 constraints={"mu": "positive", "theta": [0, 0.999], "omega": "positive"},
)
 state = rebuild_state(window, eta)
...

```



**最重要のleakage防止**：その予測窓内で起きた事件を取り込んでから同じ窓を予測してはいけない。必ず「予測→評価→取り込み→再学習」の順とする。

## Step 8：baselineも同じ情報条件で更新する

- Uniform
- 365日rolling count
- 28日／56日rolling KDE
- Prospective hotspot
- 曜日・shift別seasonal count
- 固定パラメータETAS

baselineにも同じavailable\_time制約を適用する。適応ETASだけに新しい情報を与えない。

## Step 9：保存する評価指標

### 場所予測

$$\text{Hit Rate} = \frac{\text{予測区域内で発生した事件数}}{\text{評価区域内の全事件数}}$$

$$\text{PAI} = \frac{n/N}{a/A}$$

- Hit Rate–Area curveとAUC
- Precision@20 cells、Recall@20 cells
- PEI
- 週次・全期間集計とblock bootstrap confidence interval

### 確率予測

- out-of-sample point-process log likelihood
- Poisson deviance
- 期待件数と実件数のcalibration plot
- time-rescaling residual診断

### 適応モデル固有

- $\mu$ 、 $\theta$ 、 $\omega$ の時系列
- branching ratioの安定性
- 前日mapとのJaccard similarity
- 上位20格子の入れ替わり率
- パラメータ更新直後の性能変化
- report delay別の性能低下
- 1 eventあたりupdate時間、週次refit時間、peak memory

通常のclassification accuracyは、非発生格子が圧倒的に多いため主要指標にしない。

## Step 10：最低限作る図

1. ある予測日の総risk map、上位20格子、予測後に起きた事件。
2. 同日のbackground  $\mu$ 、trigger  $\theta\omega z$ 、合計riskの三分解図。

3. M0-M4のHit Rate-Area curve。
4. 日別・週別PAI差。
5.  $\mu$ 、 $\theta$ 、 $\omega$ と事件件数の時系列。
6. 固定ETASと適応ETASのrisk map差分。
7. map Jaccard similarityと上位格子入れ替わり率。
8. event\_time評価とavailable\_time評価の比較。
9. neighborhood別の上位格子選択日数。
10. runtimeと精度のtrade-off。

## 7. 推奨する適応設定

項目	初期設定	感度分析
犯罪種	BURGLARY	VEHICLE - STOLEN
空間	1 Division、150 m格子	300 m、500 m、3 Divisions
予測幅	24時間	12時間shift
履歴窓	365日	90日、180日、730日
状態更新	新着事件ごと	日次一括
parameter更新	7日ごと	1日、14日、28日ごと
忘却係数	$\rho=1.0$ から開始	0.98、0.995
空間励起	同一格子のみ	隣接格子Gaussian kernel

推奨主モデルは、**事件ごとの状態更新+7日ごとの365日rolling refit+ $\rho=1.0$** である。これを再現できた後、忘却係数と日次更新を追加する。適応機構を一度に増やさず、何が予測を変えたかをablationで分離する。

## 8. 観測・巡回feedback実験

適応化は、新しい傾向への追従を可能にする一方、観測biasにも速く追従する。

### 設定

- 真の犯罪発生過程：固定holdoutまたは既知のsynthetic ETAS。
- 通常格子の観測確率 $p_0$ 。
- 上位予測格子の観測確率 $p_1 > p_0$ 。
- 観測された事件だけを次の状態・parameter更新へ入力。

- 比較：真の全事件／観測事件のみ／観測確率補正。
- 適応頻度：固定、週次、日次。

## 観察項目

- 真の発生分布が一定でも予測集中が増幅するか。
- 固定ETASより適応ETASで増幅が速いか。
- 重点格子の選択頻度が初期条件へ依存するか。
- police-initiated offenseと被害届中心property crimeで結果が変わるか。
- inverse-propensity weighting等で予測集中が弱まるか。

これは実データにbiasがあると先に結論するものではなく、**観測機構と適応速度の組み合わせが出力をどう変えるか**を確認する感度分析である。

## 9. 外部再現と複雑モデルへの接続

### Chicago

- 公式データ：[Crimes - 2001 to Present](#)
- 境界：[Police District Boundaries](#)
- 公開実装：[MatthewDaws/SEPP](#)

LAPDで固定したpipelineを、Chicagoの1 District・1犯罪種・3年程度へ移植する。パラメータ更新頻度をChicagoに合わせて再選択せず、最初はLos Angelesで固定した条件のtransportabilityを検証する。

### 複雑化の比較候補

- 空間共変量を含むETAS：[Reinhart & Greenhouse \(2018\)](#)
- RKHS／Gaussian process近似：[Flaxman et al. \(2018\)](#)
- 深層時空間crime forecasting：[Wang et al. \(2019\)](#)
- Transformer Hawkes Process：[Zuo et al. \(2020\)](#)
- crime／landmark／道路networkを含むgraph attention point process：[Dong, Mateu & Xie \(2024\)](#)

これらは同一データ・同一予測窓・同一面積予算で比較して初めて、適応ETASより高精度か判断できる。論文ごとのaccuracy値を直接比較しない。

PhiladelphiaのHunchLab型GBMは、適応ETAS実験完成後の異なるモデル族として扱う。実運用研究：Ratcliffe et al. (2021)。500 ft格子、短期・長期履歴、Risk Terrain、社会人口統計、時間周期を特徴量とする構造的近似は可能だが、製品codeの完全再現ではない。

## 10. 実験記録template

- run\_id／実行日時／Git commit
- data提供元・取得日時・URL・hash
- event\_timeとavailable\_timeの定義
- 抽出期間／地域／犯罪種
- raw件数／除外件数と理由／最終件数
- CRS／grid size／境界処理
- forecast horizon／history window／area budget
- model式／kernel／constraints／seed
- 初期parameterと各更新後parameter
- 状態更新回数／parameter更新頻度／忘却係数
- train／validation／test期間
- metricsとconfidence interval
- 予測地図、分解図、parameter trajectory、error map
- runtime／memory
- 実装変更・失敗・未解決点
- 解釈可能範囲と主張してはいけない範囲

## 11. 実装の合格条件

### 数値実装

- ☐ 固定parameterで、逐次計算したzと全履歴から再計算したzが許容誤差内で一致する。
- ☐ riskの数値積分と解析式が一致する。
- ☐ log likelihoodがEM／最適化反復で悪化していない。

- ☐  $\mu > 0$ 、 $\omega > 0$ 、 $0 \leq \theta < 1$ を満たす。
- ☐  $\omega$ 更新後にstateを再構築している。
- ☐ 同じseed・data snapshotで結果を再現できる。

## 時系列評価

- ☐ random splitを使用していない。
- ☐ 予測時点より後のevent/reportを入力していない。
- ☐ hyperparameterをtest期間で選んでいない。
- ☐ 全modelへ同じavailable\_time制約を適用した。
- ☐ 同一grid・予測窓・面積予算で比較した。
- ☐ 犯罪ゼロ日を含む集計規則を事前に固定した。

## 出力解釈

- ☐ 予測は事件の断定ではなく条件付きriskであると明記した。
- ☐ 予測精度と巡回効果を分けた。
- ☐ PredPol製品の完全再現とは表記していない。
- ☐ 地域集中の可視化を差別的影響の因果証明として扱っていない。

## 12. 着手順

1. LAPDの1 Division・BURGLARY・24時間予測で365日count baselineを完成する。
2. 固定パラメータETASを実装する。
3. eventごとの状態更新を実装し、一括再計算との一致testを行う。
4. 7日ごとの365日rolling refitを追加する。
5. 固定／state-online／adaptiveのrolling backtestを行う。
6. 12時間shiftへ細分化し、上位20格子を出力する。
7. event\_timeとavailable\_timeを比較する。
8. 忘却係数、日次更新、空間kernelを一つずつ追加する。
9. Chicagoで外部再現する。

10. 観測・巡回feedback simulationを実行する。

11. 必要に応じてOnline Hawkes、RKHS、deep modelと比較する。



**最初の実装goal**：一つのJupyter Notebookで、data取得  
→ cleaning → 150 m格子 → 初期ETAS fit → 事件ごとのstate更新 → 週次  
parameter refit → 翌日backtest → PAI / log likelihood → 予測map・  
parameter trajectoryまで再現する。最初に完成させる適応ETASは、事  
件ごとの状態更新と週次再推定を組み合わせたものとする。

## 13. 参考資料

### 公式データ

- [Los Angeles Crime Data from 2010 to 2019](#)
- [Los Angeles GeoHub / LAPD MapServer](#)
- [Chicago Crimes - 2001 to Present](#)
- [Chicago Police District Boundaries](#)
- [Philadelphia Crime Incidents](#)
- [data.police.uk](#)

### ETAS・SEPP・オンライン学習

- [Mohler et al. \(2011\), Self-Exciting Point Process Modeling of Crime](#)
- [Mohler et al. \(2015\), Randomized Controlled Field Trials of Predictive Policing](#)
- [Yang et al. \(2017\), Online Learning for Multivariate Hawkes Processes](#)
- [MatthewDaws/SEPP](#)
- [OpenCP/PredictCode](#)

### 比較モデル・実運用評価

- [Reinhart & Greenhouse \(2018\), Self-exciting Point Processes with Spatial Covariates](#)
- [Flaxman et al. \(2018\), Scalable High-resolution Forecasting of Sparse Spatiotemporal Events](#)

- Wang et al. (2019), Deep Learning for Real-Time Crime Forecasting
- Ratcliffe et al. (2021), The Philadelphia Predictive Policing Experiment
- Zuo et al. (2020), Transformer Hawkes Process
- Dong, Mateu & Xie (2024), Spatio-Temporal-Network Point Processes for Modeling Crime Events with Landmarks

## 関連Notion資料

- Predictive Policingに関する調査
- 詳細事例② PredPol／Geolitica — 技術・運用・評価
- 詳細事例④ Philadelphia 3PE — 予測と巡回方法の比較実験
- Conditions of benefits and risks when algorithmic technology is implemented for public sector policing and fraud detection: a systematic literature review